Лабораторная работа 1. Кто снизил активность и почему

Курс: Data Science Camp, «Теория DS» **Срок сдачи:** 9 ноября 23:59 финальное время (смотрится последний коммит до него) **Вес в итоговой оценке:** см. раздел «Как это оценивается»

> Банк «Меридиан» вымышлен, все данные синтетические. Ни одно число не описывает реальные данные или процессы какого-либо банка.

---

1. Ситуация

Вы аналитик в банке «Меридиан». К вам приходит руководитель департамента розничных продуктов со следующей задачей.

За последние полгода банк видит, что клиенты стали реже пользоваться картами. Департамент планирует кампанию по возврату активности и просит понять, к кому с ней идти.

Ограничения, которые он называет сразу:

- **Бюджет кампании — 2000 клиентов.** Больше не получится.
- **Нужны группы, а не список фамилий.** Под каждую группу готовится отдельная коммуникация, её подготовка и согласование стоят примерно одинаковых усилий независимо от размера группы. Поэтому групп должно быть от 3 до 5, и **группа меньше 150 человек не рассматривается**.
- **Каждая группа должна быть описана правилом по признакам клиента**, а не перечислением. Придёт новая выгрузка — должно быть понятно, попадает в группу новый клиент или нет.
- **По каждой группе нужно понимать, за счёт чего упала активность.** Иначе непонятно, что этим людям предлагать.
- Коммуникация возможна только при наличии согласия клиента на неё.

Руководитель не технический специалист. Он прочитает ваш отчёт и примет по нему решение.

---

2. Что требуется сделать

1. **Определить, что считать снижением активности.** В данных нет поля «активность». Вы выбираете метрику сами, считаете её **в расчёте на месяц** и обосновываете выбор. Отдельно напишите, какое снижение ваша метрика **не увидит**.

2. **Выяснить, у кого и за счёт чего активность упала.** Разрезы в анализе могут и должны пересекаться: один и тот же клиент может быть подвержен нескольким причинам сразу. Если так — опишите это.

3. **Выделить от 3 до 5 групп.** Правило каждой группы состоит из двух обязательных частей:

   - **кто это** — признак клиента (сегмент, уровень лояльности, наличие приложения, возраст, тип карты, город) или характеристика его трат (категория, канал);
   - **что с ними произошло** — характер падения.

   Порог по величине падения может входить в правило как уточнение, но **не может быть его содержанием**. «Клиенты с падением больше 70%» — это не группа: заказчик из такого описания не понимает, кто эти люди и о чём с ними говорить. «Клиенты массового сегмента без мобильного приложения, у которых активность сошла почти на нет к концу периода» — группа.

   Правило должно быть применимо к клиенту из новой выгрузки: все поля, которые в него входят, должны считаться из тех же двух таблиц.

4. **В итоговом списке каждый клиент ровно в одной группе.** Если клиент подходит под несколько — выберете явно к какой группе клиент больше всего подходит.

5. **Соблюсти лимиты:** суммарно не более 2000 уникальных клиентов, в каждой группе не менее 150.

6. **Явно назвать, кого в кампанию не включаем и почему.** Отдельный подраздел отчёта.

7. **Назвать ограничения данных** и то, чего в них нет.

Период

```
None
данные охватывают  2024-01-01 .. 2025-06-30
```

```
базовый период     2024 год              (12 месяцев)
оцениваемый период январь – июнь 2025    (6 месяцев)
```

Обратите внимание: окна разной длины.

Обязательные блоки работы

Отсутствие любого из них снимает баллы:

1. Аудит качества данных.
2. Пропуски: не только доля, но и предположение о механизме.
3. Выбросы: обнаружение отдельно от решения, что с ними делать.
4. Описательные статистики с обоснованием выбора мер центра и разброса.
5. Распределения и визуальный анализ.
6. Частотные характеристики категориальных признаков.
7. Связи между признаками и разрезы.
8. Ответ на вопрос заказчика, ограничения, журнал изменений.

---

3. Данные

Вам выдаётся персональный набор из двух файлов. **У каждого студента свой набор** — числа и конкретные обстоятельства различаются, общая структура одинакова. Работа, сделанная на чужих данных, не засчитывается.

Файлы выгружены из разных систем: кодировки, разделители и формат десятичного разделителя в них **не совпадают**. Определите их самостоятельно.

`clients.csv` — справочник действующих клиентов на 30.06.2025

поле	**описание**
`client_id`	идентификатор клиента
`birth_date`	дата рождения
`gender`	пол
`city`	город проживания
`segment`	сегмент: Массовый, Зарплатный, Премиальный, Private

поле	описание
loyalty_tier	уровень лояльности: Базовый, Серебро, Золото, Платина
card_type	тип карты: Дебетовая, Кредитная, Премиальная
registration_date	дата прихода клиента в банк
card_open_date	дата открытия текущей карты
income_source	источник зарплаты со слов клиента
monthly_income	ежемесячный доход, рублей
has_mobile_app	установлено ли мобильное приложение
app_last_login	месяц последнего входа в приложение
satisfaction_score	оценка качества обслуживания по опросу, от 1 до 5
branch_code	код отделения обслуживания
marketing_opt_in	согласие на маркетинговую коммуникацию

transactions.csv — операции по картам

поле	описание
txn_id	идентификатор операции
client_id	идентификатор клиента
txn_datetime	дата и время операции
amount	сумма операции
currency	валюта операции
category	категория траты, одна из девяти
mcc_code	код типа торговой точки, соответствует категории

поле	описание
`channel`	способ оплаты: Карта, Токен, СБП, Онлайн-банк
`status`	статус операции: успешно, отклонено, возврат

Пояснение к каналам: **«Карта»** — оплата пластиковой картой, **«Токен»** — оплата смартфоном или часами через Pay-сервис, **«СБП»** — перевод по Системе быстрых платежей, **«Онлайн-банк»** — операция в интернет-банке.

> **Важно.** Это описание составлено владельцем источника данных и может расходиться с тем, что в файлах на самом деле. Проверьте сами. Расхождение между описанием и фактом — это находка, которую нужно зафиксировать, а не повод считать, что файл испорчен.

---

4. Что сдавать

Пять файлов в репозитории. Имя репозитория Surname_Name_Lab1. Репозиторий делаете публичным.

`01_analysis.ipynb` — рабочий ноутбук

Загрузка **сырых** выданных файлов, аудит качества, препроцессинг, журнал изменений, всё исследование. Графиков столько, сколько нужно. В конце сохраняет очищенную таблицу и журнал.

Должен исполняться сверху вниз без ошибок на выданном вам сыром файле. Черновые эксперименты и тупики сюда не входят — это чистовой рабочий документ, а не черновик.

На выходе: очищенная таблица (формат на ваш выбор — `parquet` сохраняет типы и требует `pip install pyarrow`, `csv` проще, но типы придётся восстанавливать) и `cleaning_log.csv`. Промежуточные таблицы вроде метрик по клиентам сохранять тоже можно.

`02_report.ipynb` — отчёт

Читает очищенную таблицу, построенную первым ноутбуком. Строит только финальные графики и содержит текст аналитической записки в markdown-ячейках.

`report.pdf` — собранный отчёт

```Shell
jupyter nbconvert --to webpdf --no-input --execute 02_report.ipynb --output
report.pdf
```

`cleaning_log.csv` — журнал изменений

Таблица, в которой зафиксировано **каждое решение**, изменившее данные. Строка журнала соответствует решению, а не записи: если вы привели семнадцать написаний города к шести, это одна строка журнала, а не семнадцать.

Обязательные колонки:

колонка	**что в ней**
`field`	поле, которого касается решение
`issue`	что обнаружено
`scope`	кого затронуло: правило отбора или идентификаторы записей
`n_rows`	сколько строк затронуто
`value_before`	что было (значение, диапазон или пример)
`action`	что сделано: исправлено, удалено, заполнено, ограничено, оставлено
`value_after`	что стало
`rationale`	основание решения

Пример двух строк:

```None
field      issue                    scope               n_rows  value_before
action        value_after  rationale
city       разнобой написания       все строки             5671  «г. Москва»
нормализация  «Москва»     сверено со списком городов, смысл не меняется
amount     сумма выше границы МКР   txn_id 100417,814502       2  58100.00
оставлено     58100.00     причину установить не удалось, исходник сохранён,
проверена чувствительность выводов
```

Журнал нужен не ради формы. Через месяц ни вы, ни ваш коллега не вспомните, почему вы поступили так. В отчёт попадает не сам журнал, а его сводка (см. ниже).

В журнал обязательно оставлять те решения/операции, которые привели к изменению данных (Например: операция "удалить дубликаты" приводит к изменению данных -> логируем в журнале с обоснованием, т.е. с ответом на вопрос "зачем вы это сделали?") Те операции/решения, которые не приводят к изменению данных, логируем по желанию (Например: решение "оставить некоторые выбросы" не приводит к изменению данных, однако если вы данное решение посчитали важым, то лучше логировать с обоснованием)

`campaign_list.csv` — итоговый список

Две колонки: `client_id` и `group` (метка группы). Не более 2000 строк, каждый `client_id` встречается один раз.

Структура отчёта

Та же, что разбиралась на практикуме третьей недели:

1. **Главное** — 3–5 выводов с числами, сверху, до любых графиков.
2. **Контекст** — какую задачу решаем.
3. **Данные и ограничения** — период, n, что исключено и почему, чего в данных нет. Здесь же **одним абзацем**: какую метрику активности вы выбрали, как она считается и какое снижение не увидит. Это решение влияет на все дальнейшие выводы, поэтому читатель должен узнать о нём до них, а не в конце.
4. **Находки** — по одной на подраздел, заголовок-вывод, под ним график.
5. **Группы для кампании** — описание, размер, причина падения.
6. **Кого не включаем и почему.**
7. **Что проверили и что не подтвердилось** — 3–5 строк, по одной на гипотезу, с числом.
8. **Приложение** — сводка журнала изменений (по типам нарушений: поле, что найдено, сколько строк, что сделано — 5–10 строк, а не весь журнал целиком), детали методики (точные формулы, фильтры, пороги и их значения), и 3–5 строк о том, как вы использовали ИИ.

Почему методика в приложении, а не в начале: отчёт читает руководитель, который принимает решение, а не повторяет расчёт. Ему нужен вывод и основание для доверия к нему. Формулы и пороги нужны другому человеку и в другой момент — когда расчёт будут оспаривать или повторять через полгода. Поэтому в основной части остаётся то, что меняет понимание выводов, а воспроизводимые детали уезжают вниз. Это та же логика «вывод сверху», что и у структуры отчёта в целом.

Ограничения объёма

Не более 6 страниц и не более 8 графиков в отчёте. Это часть задания: выбрать, что показать. В рабочем ноутбуке ограничений нет.

Требование воспроизводимости

Все графики и таблицы в отчёте получены исполнением кода. Числа в тексте должны совпадать с выводом кода. Это проверяется.

---

5. Чем можно и чем нельзя пользоваться

Можно: pandas, numpy, matplotlib, seaborn.

Нельзя: модели машинного обучения. Этого материала у вас ещё не было, и защитить такой результат вы не сможете. Выводы делаются на описательных мерах и графиках.

Про ИИ-ассистентов. Пользоваться можно и нужно. Добавьте в приложение отчёта 3–5 строк: для чего использовали и что из полученного проверили сами.

---

6. Как это оценивается

Накопительная схема, 100 баллов. **Защита обязательна: без неё работа не засчитывается независимо от качества.**

Офлайн-проверка отчёта — 60 баллов

что оценивается	**баллов**
Аудит качества и препроцессинг: найденные проблемы, журнал изменений с основаниями	15
Метрика активности: выбор, способ расчёта, обоснование, что она не видит	10
Исследование: распределения, частотные характеристики, разрезы, динамика по месяцам	15

что оценивается	баллов
Группы: правило из двух частей (кто и что произошло), объяснение причины, непересечение, лимиты	12
Исключения и ограничения: кого не берём и почему, чего в данных нет	8

Защита — 40 баллов

что оценивается	баллов
Понимание собственного кода и принятых решений	15
Ответы на вопросы по данным и находкам	15
Интерпретация собственных графиков	10

За что снимаются баллы

- среднее арифметическое по порядковой шкале;
- удаление выброса без проверки источника и обоснования;
- вывод без указания n, периода и единиц измерения;
- доля без знаменателя;
- график без подписей осей и единиц;
- числа в тексте не совпадают с выводом кода;
- параметры заполнения пропусков оценены не на той части данных;
- превышение лимита в 6 страниц или 8 графиков.

Баллы ставятся за обоснование решений, а не за совпадение вашего списка с каким-то «правильным». Если вы приняли другое решение и объяснили, почему, — это полный балл.

---

7. Защита

15 минут, индивидуально, по видеосвязи.